

Evaluation Master M1 IMB - Université Paris Descartes

Etude de cas : estimation de la pénétrance de la maladie d'Alzheimer associée à des variants rares dans le gène *SORL1*

2024 - 2025

Le projet se décompose en 2 exercices indépendants. Le premier consiste en une analyse de données et le second en une étude de simulation.

Le projet peut être réalisé seul ou en binôme et sera à rendre pour le **22 avril 2025** au plus tard. Il vous est demandé de rendre un **document écrit détaillé** ainsi qu'un **code R commenté**. Pensez à **faire apparaître vos noms sur chaque document rendu**. Il est aussi possible de rendre un seul document Rmarkdown (pdf+Rmd).

La qualité de la rédaction, du code et des figures sera prise en compte dans la notation. Sur les graphiques, pensez aussi aux titres des axes et aux légendes !

Si vous avez des questions : catherine.schramm@inserm.fr

Partie 1 : Analyse de l'effet d'un variant rare ajusté sur l'effet d'un variant fréquent

Cette partie est réalisée sur des données simulées pour l'exercice et qui ne reflètent pas nécessairement la réalité.

Contexte de l'étude

Nous souhaitons estimer la pénétrance de la maladie d'Alzheimer chez les porteurs d'un variant rare "perte de fonction" dans le gène *SORL1* en stratifiant sur le nombre d'allèles $\epsilon 4$ dans le gène *APOE*. Pour cela, nous avons constitué une cohorte de 27 familles recrutées à partir d'un cas index (individu atteint de la maladie d'Alzheimer ≤ 65 ans et porteur d'un variant rare dans le gène *SORL1*).

L'effet du nombre d'allèles $\epsilon 4$ dans le gène *APOE* sur le risque de développer la maladie d'Alzheimer a déjà été étudié dans de grandes cohortes, et nous avons ainsi pu en déduire le risque de base (λ_{nc}) pour les non porteurs de variant d'intérêt dans *SORL1*.

Nous décidons d'utiliser dans un premier temps le modèle de survie dont le risque instantané s'écrit :

$$\lambda(t | a, s) = \lambda_{nc}(t | a) \exp(\beta \mathbf{1}_{s=SORL1+})$$

avec a le génotype *APOE* en terme d'allèles $\epsilon 4$ (non porteur d'allèle $\epsilon 4$, hétérozygote $\epsilon 4$ c'est-à-dire porteur d'1 allèle $\epsilon 4$ ou homozygote $\epsilon 4$ c'est-à-dire porteur de 2 allèles $\epsilon 4$), s , le génotype *SORL1* (*SORL1+*: porteur d'un variant d'intérêt, *SORL1* WT [*Wild Type*]: non porteur) et β l'effet additif associé au variant de *SORL1*.

Le risque de base a déjà été estimé et a été fourni lors des séances de cours (cf TP). Il nous reste donc à estimer β . Pour estimer ce modèle, il n'est pas possible d'utiliser les fonctions déjà disponibles dans R. Nous devons donc coder nous-même cette estimation.

NB: Pour réaliser cet exercice, vous travaillerez sur la base de données “data_evaluation2025” (données simulées pour l’exercice) qui contient les informations suivantes :

- famid : identifiant de la famille
- indid : identifiant de l’individu
- patid : identifiant paternel (0 si pas d’information)
- matid : identifiant maternel (0 si pas d’information)
- sex : 1=homme et 2=femme
- index : représente l’individu par lequel la famille a été recrutée
- APOE : statut *APOE* (2 copies parmi les allèles 2, 3 et 4)
- SORL1 : statut *SORL1* (2 copies parmi 0=pas de variant et 1=présence d’un variant d’intérêt)
- status : 1=malade et 0=non malade
- age : âge du début de la maladie ou âge de censure

Question 1 : Description

- Faites une description de la base de données. Proposez notamment des descriptions de l’âge de début de la maladie et discutez de biais potentiels à partir de ce que vous observez.
- Affichez les arbres des familles 1, 8 et 20, en incluant les informations statut (malade/non malade), les âges ainsi que les génotypes *APOE* et *SORL1*. Décrivez ces arbres et déterminez les génotypes manquants à partir des informations disponibles. Complétez les génotypes manquants dans la base de données.
- Recodez des variables si nécessaire.

Question 2 : Estimation de β

- Pourquoi estimer seulement β et pas λ_{nc} directement à partir de la cohorte familiale ?
- Estimez β à partir des données en justifiant votre façon de faire.
- Tracez la courbe de pénétrance moyenne des non-porteurs et des porteurs de variant *SORL1* selon le nombre d’allèles $\varepsilon 4$ sur *APOE*.
- Ajoutez les intervalles de confiance aux deux graphiques en expliquant votre façon de faire.

Question 3 : Estimation de $\beta(t)$ dans un modèle plus complexe

Nous choisissons de complexifier le modèle en utilisant cette fois un effet des variants de *SORL1* variable dans le temps. Nous choisissons de modéliser cet effet avec une fonction constante par morceaux. En gardant les mêmes notations que précédemment, on choisit le modèle suivant :

$$\lambda(t \mid a, s) = \lambda_{nc}(t \mid a) \exp(\beta(t) \mathbf{1}_{s=SORL1+})$$

avec :

$$\beta(t) = \begin{cases} \beta_1 & \text{si } t < 70 \\ \beta_2 & \text{si } 70 \leq t < 80 \\ \beta_3 & \text{si } t \geq 80 \end{cases}$$

- Mathématiquement, exprimez $\hat{\beta}_1$, $\hat{\beta}_2$ et $\hat{\beta}_3$ en fonction des paramètres connus des données (détaillez le calcul).
- Calculez leurs valeurs à partir de la base de données.
- Tracez la pénétrance moyenne des porteurs de variant *SORL1* selon le nombre d’allèles $\varepsilon 4$ sur *APOE* à partir de ce nouveau modèle plus complexe.
- Bonus : ajoutez les intervalles de confiance.

Question 4 : conclusion

- 4.a. Quel modèle semble le plus pertinent. Sur quel(s) critère(s) vous basez-vous ?
- 4.b. A partir des résultats obtenus, écrivez une conclusion générale sur la pénétrance de la maladie d'Alzheimer chez les porteurs et non porteurs d'un variant perte de fonction dans le gène *SORL1*.
- 4.c. Discutez des axes d'amélioration que l'on pourrait aborder dans cette étude.

Partie 2 : une étude de simulation

Contexte de l'étude

Nous souhaitons estimer la pénétrance d'une maladie M chez les individus porteurs d'un variant rare du gène *GENE1*. Nous faisons l'hypothèse d'une pénétrance évoluant avec l'âge et nous voulons utiliser un modèle de survie pour estimer cette pénétrance. NB: Les non porteurs du variant d'intérêt ne sont jamais touchés par cette maladie.

S'agissant d'un variant rare, il est difficile d'inclure dans notre étude des individus porteurs de ce variant. Alors nous recrutons des familles (enrichies en porteurs de ce variant) de la manière suivante :

- un patient, < 20 ans, est suivi pour la maladie M dans notre hôpital;
- le diagnostic génétique nous informe qu'il est porteur du variant d'intérêt sur le gène *GENE1*;
- nous lui proposons de l'inclure, lui (cas index) et sa famille dans l'étude, ce que lui et sa famille acceptent;
- nous recueillons les informations phénotypiques (statut malade ou non malade et âge de début ou âge de dernière nouvelle) de tous les membres de la famille;
- nous recueillons les informations génotypiques (absence ou présence du variant d'intérêt sur le gène *GENE1*) de tous les membres de la famille.

Grâce à cette méthode nous recrutons N familles, dont certains membres sont porteurs du variant d'intérêt sur le gène *GENE1*.

Nous voulons savoir si notre méthode de recrutement nous garantit de bien estimer les paramètres d'un modèle de pénétrance basé sur un modèle de survie de type "exponentiel". Pour vérifier cela, nous faisons une étude de simulation.

Pour réaliser cette étude de simulation, il nous faut :

1. simuler une cohorte avec des familles;
2. pour chaque individu, lui attribuer un génotype et un phénotype (selon un modèle déterminé dont on connaît le paramètre θ);
3. estimer le modèle sur l'ensemble de la cohorte pour obtenir $\hat{\theta}$, l'estimation de θ ;
→ répéter ces étapes plusieurs fois pour avoir plusieurs estimations $\hat{\theta}$. Si la distribution de $\hat{\theta}$ sur l'ensemble des itérations a une moyenne proche de la vraie valeur θ qui a été utilisée pour simuler les données, alors nous pourrions dire que notre modèle d'estimation est correct.

Les étapes permettant de réaliser l'étude de simulation sont détaillées ci-dessous.


Mise en place des données de simulation : données pour une famille

1) Construire un modèle familial de 2 générations incluant 5 individus :

- génération 1 : les parents (1 père, 1 mère)
- génération 2 : les enfants (3 frères/soeurs)

dans un tableau dont les colonnes sont intitulées “famid” pour identifiant famille (tous les individus d’une même famille ont le même identifiant de famille), “indid” (pour les identifiants d’individu : père=1, mère=2, enfant=3, 4 et 5), “sexe” (1=homme, 2=femme), “patid” (identifiant du père, 0 si inconnu) et “matid” (identifiant de la mère, 0 si inconnu).

##	famid	indid	sexe	patid	matid
## 1	1	1	1	0	0
## 2	1	2	2	0	0
## 3	1	3	1	1	2
## 4	1	4	2	1	2
## 5	1	5	1	1	2



2) Générer le génotype des individus en créant la colonne **variant** qui vaut 1 si l’individu est porteur et 0 sinon. On suppose que l’un des deux parents seulement est porteur du variant. On pourra utiliser par exemple la fonction **sample** ou **rbinom** pour déterminer aléatoirement quel parent est porteur du variant. Puis on suppose que le parent porteur a une chance sur deux de le transmettre à chacun des trois enfants. On pourra utiliser les mêmes fonctions pour déterminer aléatoirement pour chaque enfant si le parent porteur lui a transmis le variant d’intérêt.

3) Générer aléatoirement pour chaque individu l’âge de début de la maladie T en utilisant la procédure suivante :

- générer aléatoirement $u \sim \mathcal{U}(0, 1)$ (c’est-à-dire u issu d’une distribution uniforme sur l’intervalle $[0 - 1]$);

```
u <- runif(n = 1, min = 0, max = 1)
```

- générer $T = -\log(u)/\theta$ où θ est la valeur de notre paramètre (effet du variant sur la pénétrance) dans le modèle exponentiel :

$$\forall t > 0, \lambda(t) = \theta, \text{ avec } \theta > 0$$

où $\lambda(t)$ est le risque instantané en fonction de l’âge chez les porteurs du variant d’intérêt dans le gène *GENE1*.


```
theta <- ...
debut <- -log(u) / theta # chez les porteurs de variant
debut <- Inf # chez les non porteurs (ils ne peuvent pas être malades)
# Astuce : cela revient à
debut <- -log(u) / (theta*variant) #variant = 1 chez les porteurs / 0 sinon
```

- 4) Générer aléatoirement pour chaque individu l'âge de censure C selon une distribution normale d'espérance 65 ans et d'écart-type 15 ans $C \sim \mathcal{N}(65, 15)$.

```
censure <- rnorm(n = 1, mean = 65, sd = 15)
```

- 5) A partir de T ("âge de debut de la maladie") et C ("âge de censure"), définissez les colonnes **statut** et **age** correspondant respectivement au statut malade (1) vs non malade (0) et à l'âge de début de la maladie (si statut = 1) ou l'âge de censure (si statut = 0). Vous aurez par exemple :

##	famid	indid	sexe	patid	matid	variant	statut	age
## 1	1	1	1	0	0	1	1	55
## 2	1	2	2	0	0	0	0	63
## 3	1	3	1	1	2	1	0	31
## 4	1	4	2	1	2	1	1	13
## 5	1	5	1	1	2	0	0	33



Sélection des familles :

- 6) Si dans cette famille, au moins l'un des trois enfants respecte le critère de sélection alors la famille est incluse dans notre cohorte. Si plusieurs enfants de la famille respectent le critère, le cas index sera choisi aléatoirement parmi eux. Ajouter une colonne "index" qui vaut 1 pour les individus cas index et 0 pour les autres. (NB : il n'y a qu'un seul cas index par famille).
- 7) Répéter les étapes 1 à 6 jusqu'à obtenir une cohorte de N familles (appelée dans la suite du document "cohorte numéro 1")

Estimation de θ dans la cohorte numéro 1 :

- 8) Appliquez un modèle exponentiel en utilisant par exemple la fonction `survreg()` du package `survival` et en déduire $\hat{\theta}$, l'estimation du paramètre θ dans la cohorte numéro 1. NB: pour le modèle $\forall t > 0$, $\lambda(t) = \theta$, avec $\theta > 0$, la fonction `survreg()` ne renvoie pas comme coefficient directement θ mais $\alpha = -\log(\theta)$ c'est-à-dire tel que $\forall t > 0$, $\lambda(t) = \exp(-\alpha)$, avec $\theta > 0$.

```
library(survival)
model <- survreg(...)
estimation_theta <- exp(- model$coefficients)
```

Etude de simulation sur 500 itérations :

- 9) Répéter 500 fois les étapes 1 à 8 pour obtenir 500 valeurs $\hat{\theta}$.

Astuce : lorsque l'on génère aléatoirement des données, les données peuvent changer d'une fois sur l'autre. Si vous voulez que quelqu'un qui utilisera votre programme retrouve les mêmes valeurs que vous, il faudra au début du programme, fixer une graine. Cela peut se faire avec la fonction `set.seed`.

Questions

Question 1 : construction d'une base de données et application du modèle

- 1.a. Construisez aléatoirement une cohorte de 50 familles dont le cas index est sélectionné selon le critère "être malade avant 20 ans et être porteur du variant d'intérêt". Pour ce faire, respectez la procédure détaillée ci-dessus en utilisant $\theta = 0.01$ (étape 1 à 7).
- 1.b. Décrivez la cohorte obtenue.
- 1.c. Appliquez le modèle exponentiel sur l'ensemble des porteurs du variant de la cohorte numéro 1 (y compris le cas index) et trouvez la valeur de $\hat{\theta}$ correspondant (étape 8). Tracer la courbe de pénétrance moyenne associée à ce modèle.

Question 2 : construction de 500 bases de données et comparaison de $\hat{\theta}$ avec θ

- 2.a. Répétez 500 fois les étapes 1 à 8 pour obtenir 500 valeurs $\hat{\theta}$. Décrivez ces 500 valeurs (moyenne, écart-type, ...).
- 2.b. Faites un graphe de type boxplot ou violinplot de votre distribution de $\hat{\theta}$. Ajoutez sur le graphe un indicateur de la vraie valeur θ qui a été utilisée pour l'étude de simulation.
- 2.c. Que concluez vous ?

Question 3 : des études de simulation

- 3.a. Grâce à une étude de simulation, comparez la pertinence des estimations de θ selon que le cas index est inclus ou exclu des estimations. Discutez le résultat. Que pensez-vous de la méthode qui consiste à retirer le cas index ? D'après vous, comment pourrait-on améliorer nos estimations ?
- 3.b. Les estimations peuvent-elles être améliorées en augmentant le nombre de familles ? Discutez de cela en vous basant sur une étude de simulation.